

بسمه تعالی

تجارت الکترونیک

سید مهدی مهدوی مرتضوی

پروژه نهایی (بخش دوم): پروژه تشخیص تقلب در تراکنش‌های مالی

۱. خلاصه اجرایی

این پروژه یک سیستم کامل یادگیری ماشین برای تشخیص تراکنش‌های متقلبانه ارائه می‌دهد. مجموعه داده شامل ۱۰۰,۴۹۲ تراکنش با **عدم تعادل شدید (نسبت ۲۱۰ به ۱)** است. مدل نهایی Random Forest به F1-Score برابر ۰,۸۳ و Recall برابر ۰,۷۹ دست یافت که نشان‌دهنده تعادل مناسب بین تشخیص تقلب و کاهش هشدارهای کاذب است.

۲. تسک اول: پاکسازی داده و تحلیل اکتشافی

۲.۱. بارگذاری و ارزیابی اولیه:

- تعداد رکوردهای خام: ۱۰۰,۴۹۲ تراکنش
- ویژگی‌ها: ۲۸ تراکنش (V1-V28)، موجودی، شناسه (آیدی)، و برچسب کلاس (۰ و ۱)
- توزیع کلاس: ۹۹,۳۹۵ تراکنش عادی (۰) در برابر ۴۷۳ تراکنش دارای تقلب (۱)
- نسبت عدم تعادل: ۲۱۰:۱

۲.۲. فرآیند پاکسازی:

- تشخیص و حذف ۶۲۳ رکورد تکراری
- حفظ آخرین وقوع هر تراکنش منحصر به فرد (برای دریافت تراکنش با بیشترین موجودی)
- مجموعه داده نهایی: ۹۹۸۶۸ تراکنش (۹۹۳۹۵ عادی، ۴۷۳ تقلب)
- هیچ گونه مقدار گمشده (null) در دیتاست وجود ندارد

۲,۳. آمار کلیدی بر اساس کلاس

- مبلغ تراکنش:
 - عادی: میانگین = ۹۸,۱۰، میانه = ۲۶,۵۲
 - تقلب: میانگین = ۱۲۳,۸۷، میانه = ۹,۸۲
- ویژگی‌های تفکیک‌کننده (تراکنش‌های عنوان شده در فاز (تسک) دوم):
 - V13: میانگین از ۰,۰۰۸ (عادی) به ۰,۰۹۴- (تقلب)
 - V15: میانگین از ۰,۱۹۵ (عادی) به ۰,۰۷۳- (تقلب)
 - V26: میانگین از ۰,۰۲۷ (عادی) به ۰,۰۵۰- (تقلب)


۳. تسک دوم: تحلیل بصری (visualization) و کشف الگو

۳,۱. تحلیل توزیع:

- هیستوگرام‌ها نشان می‌دهند که تراکنش‌ها جملگی یک توزیع تقریباً نرمال دارند
- برخی تراکنش‌ها دارای چولگی راست و برخی دیگر چولگی چپ دارند

۳,۲. میزان تقلب در سه تراکنش خواسته شده:

- V13:
 - سپرده (واریز): ۲۳۴ (۴۹,۴۷ درصد)
 - برداشت: ۲۳۹ (۵۰,۵۳ درصد)
- V15:
 - سپرده (واریز): ۲۲۶ (۴۷,۷۸ درصد)
 - برداشت: ۲۴۷ (۵۲,۲۲ درصد)
- V26:
 - سپرده (واریز): ۲۴۱ (۵۰,۹۵ درصد)
 - برداشت: ۲۳۲ (۴۹,۰۵ درصد)



۴. تسک سوم: مدل سازی برای طبقه بندی (classification)

۴.۱. مهندسی ویژگی (افزودن ۵ ویژگی جدید):

۱. $\text{Amount_log} = \log(1 + \text{Amount})$ برای مدیریت چولگی

۲. $\text{Is_Withdrawal} = 1$ if $V15 < 0$ برای کدگذاری الگوی تقلب

۳. $V15_V17 = V15 \times V17$ برای تعامل (رتبه ۴ در MI)

۴. $V15_V26 = V15 \times V26$ برای ترکیب ویژگی های برتر

۵. $V17_V26 = V17 \times V26$ برای تعامل اضافی

۴,۲. انتخاب ویژگی با Mutual Information:

- چرا MI؟ روابط غیرخطی را دریافت می کند (برتر از همبستگی خطی)
- ۲۰ ویژگی برتر انتخاب شدند؛ از جمله ۳ ویژگی مهندسی شده در top-10

پنج ویژگی برتر (از نظر ترکیب اطلاعات (mutual information):

۱. V17 (MI=0.0216)

۲. V14 (MI=0.0202)

۳. V12 (MI=0.0184)

۴. V15_V17 (MI=0.0164) (ویژگی جدید و مهندسی شده)

۵. Is_Withdrawal (MI=0.0154) (ویژگی جدید و مهندسی شده)

۴,۳. تقسیم داده و پیش پردازش داده ها:

- تقسیم ۸۰ به ۲۰ با Stratified Split
- StandardScaler برای نرمال سازی
- مدیریت عدم تعادل: class_weight='balanced' در هر دو مدل

۴,۴. مدل های آموزش داده شده

- مدل اول: Logistic Regression (C=0.1, max_iter=1000)
- مدل دوم: Random Forest (max_depth=1, n_estimators=10)

۴,۵. معیارهای ارزیابی

- چرا Accuracy به تنهایی کافی نیست؟ با نسبت ۱:۲۱۰، پیش بینی همه تراکنش ها، به صورت عادی در نظر گرفته خواهد شد (Accuracy=99.5% اما Recall=0%)
- معیارهای اصلی:

- Precision: از پیش‌بینی‌های تقلب (تراکنش‌های پیش‌بینی شده به عنوان تقلب)، چند درصد صحیح است؟
- Recall: از تقلب‌های واقعی، چند درصد را شناسایی نموده ایم؟
- F1-Score: میانگین هارمونیک Precision و Recall
- F2-Score: وزن بیشتر به Recall (دارای اولویت در تشخیص تقلب)

۵. نتایج و مقایسه:

۵.۱. عملکرد مدل‌های استفاده شده:



	Precision	Recall	F1-Score	F2-Score
Logistic Regression	0.20	0.874	0.325	0.522
Random Forest	0.872	0.789	0.829	0.805

۵.۲. تحلیل نتایج بدست آمده از ارزیابی مدل:

- Logistic Regression: Recall بالا اما Precision پایین (دارای حدود ۸۰٪ هشدار کاذب (تراکنش‌های فاقد تقلب (نرمال)، در عمده حالات به عنوان تقلب شناسایی خواهند شد)
- Random Forest: تعادل عالی با ۸۷٪ Precision و ۷۹٪ Recall

۵.۳. confusion matrix بر اساس نتایج بدست آمده در مدل Random Forest:

- ۷۴ تقلب تشخیص داده شد (True Positives)
- ۲۱ تقلب از دست رفت (False Negatives)
- ۱۱ هشدار کاذب (False Positives)
- ۱۹,۸۶۸ عادی صحیح طبقه‌بندی شد



۵,۴: Feature Importance نشان می‌دهد هر ویژگی (Feature) چه قدر در تصمیم‌گیری مدل نقش داشته است؛ این تحلیل نشان داد:

- ویژگی V17 با امتیاز ۰,۱۵۶ مهم ترین نقش را در تشخیص تقلب ها دارد
- این یافته با کشف حاصل شده در تسک دوم (مبنی بر اینکه عمده تقلب ها در برداشت ها رخ میدهد)،

۶. نتیجه گیری، توصیه ها و تحلیل های کسب و کار:

۶,۱. ارزیابی کلی

- Random Forest با $F1=0.83$ به عملکرد بهتر و دقیق تری رسید:
 - $Recall=79\%$: از هر ۵ تقلب، ۴ مورد را به درستی شناسایی می کن
 - $Precision=87\%$: فقط ۱ مورد از هر ۸ هشدار برای تقلب، اشتباه است
- چرا RF از LR بهتر است؟
 - الگوهای غیرخطی را ضبط می کند
 - تعاملات پیچیده ویژگی را به طور خودکار کشف می کند
 - نسبت به عدم تعادل، برای طبقه بندی (classification)، مقاوم تر است

۶,۲. بینش های کسب و کار

۱. تراکنش های برداشت: مستعد برای تقلب و نیازمند نظارت بر برداشت ها
۲. مهندسی ویژگی ارزش دارد: دیدیم که ویژگی های ترکیبی V17_V26، V15_V17 و is_withdrawal در بین ۲۰ ویژگی برتر انتخاب شده برای مدلسازی (و classification) قرار داشتند؛ به ترتیب در رتبه های ۹، ۱۰ و ۱۴ (از نظر MI Score)